Ingénieur Full Stack & DevOps

Cloud AWS, CI/CD & IA générative

MOHAMED AMINE KOUBAA

+33 7 56 82 47 87 | medaminekoubaa4@gmail.com
linkedin.com/in/mohamed-amine-koubaa | mohamedaminekoubaa.com

PROFIL

Ingénieur Full Stack & DevOps avec 5 ans d'expérience sur AWS. J'ai conçu et mis en production en autonomie une passerelle LLM d'entreprise de 16 microservices et son infrastructure Terraform sur 3 environnements, avec maîtrise des coûts, sécurité multi-tenant et traçabilité de chaque appel. Spécialisé dans les architectures serverless, la CI/CD (GitLab CI, Kubernetes) et l'IA générative en production avec une gouvernance claire : plafonds de coûts, validation humaine et journal d'audit.

COMPÉTENCES TECHNIQUES

Cloud & DevOps	AWS (Lambda, API Gateway, S3, SQS, Cognito, EventBridge, CloudFront, IAM, CloudWatch) · Terraform · Terragrunt · Docker · Kubernetes · ArgoCD · GitLab CI · HashiCorp Vault
Sécurité	HashiCorp Vault · Isolation multi-tenant · Protections SSRF · Journal d'audit · AWS IAM et Cognito
IA générative	LLM · LLMOps · Gouvernance de l'IA (validation humaine, plafonds de coûts) · Agents IA (LangGraph) · Model Context Protocol (MCP) · RAG et recherche vectorielle · Langfuse · Apache Airflow
Langages & Frameworks	Python (FastAPI, Chalice) · TypeScript · JavaScript · Node.js (Express) · Angular · React / Next.js
Bases de données	MongoDB · MySQL · SQL / NoSQL
Tests & Qualité	TDD · Tests unitaires et d'intégration automatisés en CI/CD · Seuils de couverture bloquants · pytest · Vitest · Playwright
Méthodes & Outils	Agile (Scrum) · Git · Microservices · Architectures serverless et événementielles

EXPÉRIENCE PROFESSIONNELLE

Ingénieur Full Stack & DevOps, Portago

12/2024 - Aujourd'hui | Paris

LLM Gateway - Passerelle IA d'entreprise

Contexte : API compatible OpenAI qui centralise les appels des produits de l'entreprise vers les fournisseurs de LLM.
Équipe : 1 développeur & DevOps, 1 Product Owner | **Méthodologie :** Agile / Scrum

- Conception et mise en production, en autonomie, d'une passerelle LLM de 16 microservices AWS Lambda.
- Intégration des produits sans changement de code grâce à la compatibilité avec le SDK OpenAI.
- Continuité de service : bascule automatique entre fournisseurs LLM, reprises sur erreur et streaming SSE.
- Plafonnement des dépenses IA de chaque produit : budget réservé avant chaque appel et suivi FinOps.
- Sécurité : clés fournisseurs dans Vault, isolation multi-tenant, protections SSRF et journal d'audit.
- Gouvernance des outils IA : serveurs MCP classés par niveau de risque et traçabilité Langfuse.
- Infrastructure Terraform/Terragrunt sur 3 environnements, déployée par pipelines GitLab CI.
- Bibliothèque cliente Python, tests de contrat et console d'administration Angular en 3 langues.

Technologies : Python · Chalice · AWS Lambda · API Gateway · Cognito · Vault · Langfuse · MCP

Moveo - Plateforme RH de compétences et de mobilité interne

Contexte : Application qui réunit compétences, formations, mobilité interne et recrutement, avec une IA au service des collaborateurs et des RH.
Équipe : 2 développeurs, 1 DevOps, 1 Product Owner | **Méthodologie :** Agile / Scrum

- Conception de microservices serverless multi-entreprise : compétences, postes, quiz et formations.
- Génération asynchrone par IA via SQS des parcours, quiz, analyses de CV et recommandations de carrière.
- Développement de 2 assistants IA, collaborateur et RH : agent LangGraph et serveur MCP de 132 outils.
- Sécurisation des actions de l'IA : confirmation en deux étapes avant toute modification de données.
- Validation humaine par les RH des niveaux experts et des parcours terminés avant confirmation.
- Développement des 3 espaces Angular, collaborateur, RH et administrateur, limités aux droits de chaque rôle.
- Services d'agents conteneurisés sur Kubernetes, avec contrôle et synchronisation par ArgoCD.

Technologies : Python · FastAPI · IA générative · LangGraph · MCP · Kubernetes · ArgoCD · SQS · EventBridge

Développeur Full Stack & DevOps, Allence Cloud

11/2021 - 11/2024 | Tunisie

Career - Plateforme de recrutement assistée par l'IA

Contexte : Présélection automatisée des candidats : analyse des CV, score et entretiens menés par l'IA.
Équipe : 2 développeurs, 1 DevOps, 1 Product Owner | **Méthodologie :** Agile / Scrum

- Automatisation de la présélection : offres sous 4 formats, analyse des CV par LLM et score sur 100.
- Mise en œuvre d'entretiens IA sous 3 formes : écrit, vocal et téléphonique avec Twilio.
- Fiabilisation des livraisons : développement en TDD et seuil de couverture bloquant dans la CI.
- Matching candidat/offre par recherche vectorielle MongoDB sur un référentiel de 530 compétences.
- Architecture événementielle SQS et workers Lambda pour absorber les traitements IA longs.
- Agent conversationnel LangGraph et serveur MCP de 60 outils au service des recruteurs.
- Aide à la décision des recruteurs : comparaison côte à côte de deux candidats et rapports d'évaluation détaillés.
- Conteneurisation des microservices FastAPI sur Kubernetes, avec contrôle et synchronisation par ArgoCD.

Technologies : Python · FastAPI · IA générative · LangGraph · MCP · MongoDB · Twilio · OpenAI Realtime · CloudFront

PhotoEvent - Place de marché de photographie d'événements

Contexte : Vente de photos d'événements, avec recherche des photos par reconnaissance faciale.
Équipe : 2 développeurs, 1 DevOps, 1 Product Owner | **Méthodologie :** Agile / Scrum

- Livraisons indépendantes par domaine : un dépôt et un pipeline par service, 80 % de couverture minimum.
- Conception d'un backend serverless de 17 fonctions Lambda et 104 routes API, avec front Angular.
- Recherche de photos par reconnaissance faciale avec Amazon Rekognition, une collection par événement.
- Automatisation de l'import des galeries avec un DAG Apache Airflow sur Kubernetes.
- Fiabilisation du suivi financier des photographes : commandes, commissions et reversements en transactions MongoDB.
- Protection des images par filigrane et liens de téléchargement signés valables 120 secondes.
- Modération automatique des avis clients par IA générative via SQS.

Technologies : Python · Chalice · IA générative · Rekognition · Airflow · S3 · SQS · Terraform · Playwright

Développeur Full Stack, Dida Mind

02/2021 - 07/2021 | Tunisie

ProHunting - Plateforme de séjours de chasse touristique

Contexte : Réservation et gestion de séjours de chasse en Tunisie pour une clientèle européenne.
Équipe : 1 développeur, 1 Tech Lead, 1 Product Owner | **Méthodologie :** Agile / Scrum

- Conception et développement complet de l'application : API Node.js/Express et front Next.js.
- Lancement du site public en français, anglais et allemand, avec espace client et forum privé.
- Mise en place du back-office qui pilote tout le cycle d'un séjour, de la demande à la clôture.
- Notification en temps réel de l'équipe à chaque nouvelle demande de séjour avec Socket.IO.
- Intégration d'une API partenaire de réservation d'hôtels et génération automatique des documents PDF.
- Sécurisation du back-office : droits par rôle et par utilisateur, suppression réservée au super-admin.

Technologies : Node.js · Express · Next.js · TypeScript · MySQL · Socket.IO · Puppeteer · Playwright

FORMATION

- Diplôme d'ingénieur en génie logiciel - ESPRIT, Tunisie, 2024
- Licence appliquée en informatique - ISTIC Borj Cedria, Tunisie, 2021
- Formation continue : Model Context Protocol, niveaux introduction et avancé - Anthropic, 2026

CERTIFICATIONS ET LANGUES

- AWS Certified Developer – Associate - AWS, 2026
- Docker Certified Associate (DCA) - Docker, 2026
- Astronomer Certified for AI Orchestration Fundamentals - Astronomer, 2026
- Multicloud Network Associate - Aviatrix, 2025

Langues : Arabe (langue maternelle) | Français courant | Anglais courant