Ingénieur Full Stack & DevOps

Cloud AWS, CI/CD, IA générative & MCP

MOHAMED AMINE KOUBAA

+33 7 56 82 47 87 | medaminekoubaa4@gmail.com
linkedin.com/in/mohamed-amine-koubaa | mohamedaminekoubaa.com

PROFIL

Ingénieur Full Stack & DevOps avec 5 ans d'expérience sur AWS. Je conçois et livre des applications complètes, du backend Python et Node.js aux interfaces Angular, avec leur infrastructure Terraform et Kubernetes, leurs pipelines GitLab CI et leurs tests, du TDD aux tests end-to-end. J'intègre l'IA générative en production (agents IA, serveurs MCP) et j'ai notamment livré seul une passerelle LLM de 16 microservices.

COMPÉTENCES TECHNIQUES

Cloud & DevOps	AWS (Lambda, API Gateway, S3, SQS, Cognito, EventBridge, CloudFront, IAM, CloudWatch) · Terraform · Terragrunt · Docker · Kubernetes · ArgoCD · GitLab CI · HashiCorp Vault
IA générative	LLM · LLMOps · Gouvernance de l'IA (validation humaine, plafonds de coûts) · Agents IA (LangGraph) · Model Context Protocol (MCP) · Recherche vectorielle · Langfuse · Apache Airflow
Langages & Frameworks	Python (FastAPI, Chalice) · TypeScript · JavaScript · Node.js (Express) · Angular · React / Next.js
Bases de données	MongoDB · MySQL · SQL / NoSQL
Tests & Qualité	TDD · Tests unitaires et d'intégration automatisés en CI/CD · Seuils de couverture bloquants · Tests end-to-end Playwright via Playwright MCP · pytest · Vitest
Méthodes & Outils	Agile (Scrum) · Git · Microservices · Architectures serverless et événementielles

EXPÉRIENCE PROFESSIONNELLE

Ingénieur Full Stack & DevOps, Portago

12/2024 - Aujourd'hui

LLM Gateway - Passerelle IA d'entreprise

Contexte : API compatible OpenAI qui centralise les appels des produits de l'entreprise vers les fournisseurs de LLM.

- Conception et mise en production, en autonomie, d'une passerelle LLM de 16 microservices **AWS Lambda**.
- Une seule API compatible OpenAI pour chat, embeddings et audio : intégration sans changement de code.
- Continuité de service : bascule automatique entre fournisseurs LLM, reprises sur erreur et streaming SSE.
- Plafonnement des dépenses IA par produit : budget réservé avant chaque appel, alertes et suivi FinOps.
- Sécurité : clés fournisseurs dans **Vault**, isolation multi-tenant, protections SSRF et journal d'audit.
- Gouvernance des outils IA : serveurs **MCP** classés par niveau de risque et traçabilité **Langfuse**.
- Intégration facilitée pour les équipes produit : bibliothèque cliente **Python** et tests de contrat de l'API.
- Tests end-to-end de la console **Angular** avec **Playwright**, pilotés via **Playwright MCP**.
- Infrastructure **Terraform/Terragrunt** sur 3 environnements, déployée par pipelines **GitLab CI**.

Technologies : Python · Chalice · AWS Lambda · API Gateway · Cognito · Vault · Langfuse · MCP

Moveo - Plateforme RH de compétences et de mobilité interne

Contexte : Application qui réunit compétences, formations, mobilité interne et recrutement, avec une IA au service des collaborateurs et des RH.

- Développement de 2 assistants IA, collaborateur et RH : agent **LangGraph** et serveur **MCP** de 132 outils.
- Transparence de l'IA pour l'utilisateur : étapes de l'agent affichées en direct et choix du modèle dans le chat.
- Conception de microservices serverless multi-entreprise : compétences, postes, quiz et formations.
- Génération asynchrone par IA via **SQS** des parcours, quiz, analyses de CV et recommandations de carrière.
- IA sous contrôle humain : confirmation en deux étapes et validation par les RH des niveaux experts.
- Développement des 3 espaces **Angular**, collaborateur, RH et administrateur, limités aux droits de chaque rôle.
- Services d'agents conteneurisés sur **Kubernetes**, avec contrôle et synchronisation par **ArgoCD**.

Technologies : Python · FastAPI · IA générative · LangGraph · MCP · Kubernetes · ArgoCD · SQS

Développeur Full Stack & DevOps, Allence Cloud

11/2021 - 11/2024 | Tunisie

Career - Plateforme de recrutement assistée par l'IA

Contexte : Présélection automatisée des candidats : analyse des CV, score et entretiens menés par l'IA.

- Automatisation de la présélection : offres sous 4 formats, analyse des CV par LLM et score sur 100.
- Entretiens IA sous 3 formes : écrit, vocal et téléphonique avec **Twilio** et **OpenAI Realtime**.
- Matching candidat/offre par recherche vectorielle **MongoDB** sur un référentiel de 530 compétences.
- Agent IA recruteur sur **LangGraph** : serveur **MCP** de 60 outils et compression de l'historique.
- Évaluation des candidats dans le chat : QCM générés par l'agent IA et corrigés dans la conversation.
- Aide à la décision des recruteurs : comparaison côte à côte de deux candidats et rapports détaillés.
- Architecture événementielle **SQS** et workers **Lambda**, microservices **FastAPI** conteneurisés sur **Kubernetes**.
- Fiabilisation des livraisons : développement en TDD et seuil de couverture bloquant dans la CI.

Technologies : Python · FastAPI · IA générative · LangGraph · MCP · Twilio · OpenAI Realtime

PhotoEvent - Place de marché de photographie d'événements

Contexte : Vente de photos d'événements, avec recherche des photos par reconnaissance faciale.

- Conception d'un backend serverless de 17 fonctions **Lambda** et 104 routes API, avec front **Angular**.
- Recherche de photos par reconnaissance faciale avec **Amazon Rekognition**, une collection par événement.
- Automatisation de l'import des galeries avec un DAG **Apache Airflow** sur **Kubernetes**.
- Suivi financier fiabilisé des photographes : commissions et reversements en transactions **MongoDB**.
- Modération des avis par IA générative et protection des images par filigrane et liens signés.
- Création du parcours d'inscription des photographes : dépôt des documents légaux et validation par l'administrateur.
- Mise en place du support client : tickets priorisés, suivi de statut et notifications e-mail via **SQS**.
- Tests end-to-end du front **Angular** avec **Playwright MCP**, en complément des tests pytest du backend.
- Livraisons indépendantes par domaine : un dépôt et un pipeline par service, 80 % de couverture minimum.

Technologies : Python · Chalice · IA générative · Rekognition · Airflow · S3 · SQS · Terraform · Playwright

Développeur Full Stack, Dida Mind

02/2021 - 07/2021 | Tunisie

ProHunting - Plateforme de séjours de chasse touristique

Contexte : Réservation et gestion de séjours de chasse en Tunisie pour une clientèle européenne.

- Conception et développement complet de l'application : API **Node.js/Express** et front **Next.js**.
- Mise en place du back-office qui pilote tout le cycle d'un séjour, de la demande à la clôture.
- Conformité réglementaire : autorisations de chasse suivies par zone et par jour, champs officiels contrôlés à la saisie.
- Intégration d'une API partenaire de réservation d'hôtels et notifications en temps réel avec **Socket.IO**.
- Lancement du site public en français, anglais et allemand, avec contenu et SEO gérés par l'équipe.
- Automatisation des documents de séjour : modèles à champs de fusion et génération PDF avec **Puppeteer**.
- Sécurisation du back-office : droits par rôle et par utilisateur, suppression réservée au super-admin.

Technologies : Node.js · Express · Next.js · TypeScript · MySQL · Socket.IO · Puppeteer · Playwright

FORMATION

- Diplôme d'ingénieur en génie logiciel - ESPRIT, Tunisie, 2024
- Licence appliquée en informatique - ISTIC Borj Cedria, Tunisie, 2021

CERTIFICATIONS ET LANGUES

- AWS Certified Developer – Associate - AWS, 2026
- Docker Certified Associate (DCA) - Docker, 2026
- Astronomer Certified for AI Orchestration Fundamentals - Astronomer, 2026
- Model Context Protocol: Advanced Topics - Anthropic, 2026
- Introduction to Model Context Protocol - Anthropic, 2026
- Multicloud Network Associate - Aviatrix, 2025

Langues : Français courant | Anglais courant | Arabe (langue maternelle)